

Cvičení MMID č. 7 - Průběžná MNČ

V předchozích cvičeních jsme odvodili, že pro identifikaci se používá vztah výpočtu metody nejmenších čtverců dle následujícího vzorce. Pokud hodnotu kovarianční matice v k -tém kroku označíme jako $P(k)$:

$$\theta(k) = \left(\sum_{i=1}^k \varphi(i) \varphi(i)^T \right)^{-1} \sum_{i=1}^k \varphi(i) y(i) = P(k) \sum_{i=1}^k \varphi(i) y(i)$$

Dále pokud se pokusíme předchozí vztah vyjádřit v přírůstkovém tvaru, tedy $\theta(k) = \theta(k-1) + \Delta$, pak po delších úpravách vyjde:

$$\begin{aligned} K(k) &= P(k) \varphi(k) \\ \epsilon(k) &= y(k) - \varphi(k)^T \theta(k-1) \\ \theta(k) &= \theta(k-1) + K(k) \epsilon(k) \end{aligned}$$

Nyní je potřeba aplikovat lemmu o inverzi matice P :

$$P(k) = P(k-1) - \frac{P(k-1) \varphi(k) \varphi(k)^T P(k-1)}{1 + \varphi(k)^T P(k-1) \varphi(k)}$$

Pokud zkompletujeme všechny získané vzorce, do jedné sady rovnic, kterou následně upravíme za pomoci standardních maticových násobení, dostaneme:

$$\begin{aligned} \epsilon(k) &= y(k) - \varphi(k)^T \theta(k-1) \\ K(k) &= \frac{P(k-1) \varphi(k)}{1 + \varphi(k)^T P(k-1) \varphi(k)} \\ P(k) &= P(k-1) - K(k) \varphi(k)^T P(k-1) \\ \theta(k) &= \theta(k-1) + K(k) \epsilon(k) \end{aligned}$$

Pozor na pořadí jednotlivých výpočtů !!!!

Na počátku volíme matici P diagonální, s velmi vysokými hodnotami na diagonále ($1e4 - 1e6$), Počáteční nastavení vektoru odhadovaných parametrů $\theta = (1 \ 0 \ 0 \ 0 \dots)^T$

Úkol 1: Naprogramujte MNČ jako funkci v matlabu, jejímž vstupem budou vektory vstupů a výstupů, počáteční hodnoty matic P a θ , a výstupem bude matice, obsahující jednotlivé vektory odhadnutých parametrů v čase. (nutný for-cyklus přes všechny hodnoty vstupů a výstupů).

Úkol 2: Zobrazte v grafu průběh hodnot jednotlivých identifikovaných parametrů a diskutujte průběhy.

Koeficient zapomínání

Vzhledem k tomu, že se v matici uchovávají všechny hodnoty od počátku měření, dochází k tomu, že nové hodnoty jsou ukládány s menší vahou, a případné změny v soustavě nereflektují změny v identifikovaných parametrech. Proto se zavádí tzv. Koeficient zapomínání, který umožňuje zapomínat starší hodnoty, a nové hodnoty upřednostňuje. Nevýhodou je, že soustava pak nemusí konvergovat. Koeficient zapomínání λ se volí v rozsahu 0.95 – 0.99. Výhodou je, že při koeficientu 0.99 hodnoty v matici P nerostou do nekonečna a ustálí se na vysoké hodnotě. Upravené vzorce tedy jsou:

$$\begin{aligned}\epsilon(k) &= y(k) - \varphi(k)^T \theta(k-1) \\ K(k) &= \frac{P(k-1) \varphi(k)}{\lambda(k) + \varphi(k)^T P(k-1) \varphi(k)} \\ P(k) &= \frac{1}{\lambda(k)} (P(k-1) - K(k) \varphi(k)^T P(k-1)) \\ \theta(k) &= \theta(k-1) + K(k) \epsilon(k)\end{aligned}$$

Úkol 3: Upravte předchozí funkci tak, aby její výpočet odpovídal výpočtu se statickým koeficientem zapomínání.

Úkol 4: opět zobrazte průběh identifikovaných hodnot a diskutujte zjištěné odlišnosti v grafech.

Proměnný koeficient zapomínání

Další úpravou předchozího algoritmu je možné docílit „přeidentifikování“ soustavy v oblastech, kde se hojně projeví dynamické parametry soustavy (skok na vstupu soustavy). Tudíž koeficient zapomínání se volí jako dynamický, s následující rovnicí:

$$\begin{aligned}\lambda(k) &= 0.99 \lambda(k-1) + (1 - 0.99) \\ \lambda(0) &= 0.95\end{aligned}$$

V okamžiku, pokud na vstupu soustavy se objeví vhodný signál, který bude lépe vybuzovat danou soustavu, programem (natvrdo) se sníží hodnota λ na nejnižší úroveň 0.95 – tím se docílí toho, že identifikace bude více citlivá na nové parametry soustavy a lépe tak zachytí změny jejich parametrů.

Úkol 5: Upravte předchozí funkci tak, aby prováděla dynamickou změnu parametrů na základě zjištěných vhodných vlastností ve vstupním signálu. Opět zobrazte jednotlivé průběhy identifikovaných parametrů v čase.